JURNAL STATISTIKA DAN APLIKASINYA

e-ISSN 2620 – 8369
VOLUME X (ISSUE X) MONTH YEAR: XX-XX
https://doi.org/10.21009/JSA.081XX

ANALISIS DAN PREDIKSI KESELAMATAN PENUMPANG KAPAL TITANIC MENGGUNAKAN ALGORITMA RANDOM FOREST

Muhammad Fahri Novarian (1314623014)
Program Studi Statistika, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Negeri Jakarta, Kelurahan Rawamangun, Kecamatan Pulogadung, Jakarta Timur 12330, Indonesia
Corresponding author's e-mail: muhammad.fahri.novarian@mhs.unj.ac.id

Article History:

Received: date, month year
Revised: date, month year
Accepted: date, month year
Published: date, month year
Available online.

Keywords:

Random Forest, Titanic Dataset, Classification, Data Science, Machine Learning, Passenger Survival Prediction

ABSTRACT

Kecelakaan kapal Titanic merupakan salah satu peristiwa bersejarah yang sering digunakan sebagai studi kasus dalam penerapan data science dan machine learning. Penelitian ini bertujuan untuk memprediksi keselamatan penumpang Titanic menggunakan algoritma Random Forest Classifier. Dataset yang digunakan terdiri dari data penumpang dengan berbagai karakteristik, seperti kelas penumpang, jenis kelamin, usia, tarif, serta pelabuhan keberangkatan. Tahapan penelitian meliputi Exploratory Data Analysis (EDA), data preparation yang mencakup penanganan missing value, penghapusan variabel noise, feature encoding, serta penanganan data tidak seimbang menggunakan teknik oversampling. Data kemudian dibagi menjadi data latih dan data uji untuk membangun dan mengevaluasi model. Hasil evaluasi menunjukkan bahwa model Random Forest mampu memberikan performa yang baik dengan nilai akurasi sebesar 91% pada data uji. Selain itu, model menunjukkan kemampuan yang seimbang dalam mengklasifikasikan penumpang yang selamat dan tidak selamat berdasarkan nilai precision, recall, dan F1-score. Model yang telah dibangun selanjutnya diterapkan untuk memprediksi data penumpang baru, dengan hasil distribusi prediksi menunjukkan bahwa sebagian besar penumpang diprediksi tidak selamat. Hasil penelitian ini menunjukkan bahwa algoritma Random Forest efektif digunakan untuk memprediksi keselamatan penumpang Titanic.

This article is an open access article distributed under the terms and conditions of the Creative Commons Attribution-ShareAlike 4.0 International License.

1. PENDAHULUAN

Latar Belakang

Keselamatan penumpang kapal merupakan isu penting yang terus mendapat perhatian, mengingat kecelakaan transportasi laut dapat menimbulkan dampak serius, baik dari sisi keselamatan jiwa maupun kerugian ekonomi. Salah satu peristiwa yang sering dijadikan sebagai studi kasus dalam analisis keselamatan penumpang adalah tenggelamnya kapal RMS Titanic pada tahun 1912. Peristiwa ini menunjukkan bahwa keselamatan penumpang tidak hanya dipengaruhi oleh faktor teknis, tetapi juga oleh karakteristik individu penumpang.

Dataset Titanic memuat berbagai karakteristik penumpang, seperti kelas tiket, usia, jenis kelamin, tarif tiket, serta pelabuhan keberangkatan. Informasi tersebut memungkinkan dilakukan analisis terhadap pola dan hubungan antara karakteristik penumpang dan status keselamatan. Penggunaan dataset ini memberikan peluang untuk memahami bagaimana perbedaan karakteristik penumpang dapat berkaitan dengan peluang keselamatan dalam suatu kecelakaan laut.

Dalam konteks analisis keselamatan dan mitigasi risiko, pendekatan berbasis data dapat digunakan untuk mempelajari pola keselamatan penumpang secara lebih sistematis. Melalui proses analisis data

How to cite this article:
Author(s), "ARTICLE TITLE", Journal Statistika dan Aplikasinya, vol. x, iss. x, pp. xx – xx, Month, Year

Copyright © 2024 Author(s)
Journal homepage: https://journal.unj.ac.id/unj/index.php/statistika
Journal e-mail: jsa@unj.ac.id
Research Article · Open Access

yang mencakup pemahaman karakteristik variabel, pra-pemrosesan data, serta pemodelan klasifikasi, informasi historis dapat dimanfaatkan untuk mengurangi ketidakpastian dalam penilaian keselamatan penumpang.

Penelitian ini menggunakan data penumpang Titanic untuk melakukan analisis dan pemodelan keselamatan penumpang menggunakan algoritma Random Forest. Model yang dibangun selanjutnya diterapkan pada dataset lain yang memiliki karakteristik serupa namun tidak memiliki informasi status keselamatan, sehingga dapat digunakan untuk menghasilkan prediksi keselamatan penumpang berdasarkan data yang tersedia.

Tujuan Penelitian

Penelitian ini bertujuan untuk menganalisis dan memodelkan status keselamatan penumpang kapal Titanic berdasarkan karakteristik individu penumpang yang tersedia dalam dataset. Pemodelan dilakukan menggunakan algoritma Random Forest untuk mempelajari pola keselamatan penumpang dan menghasilkan prediksi pada data penumpang lain yang memiliki karakteristik serupa.

Adapun tujuan khusus dari penelitian ini adalah:

1. Melakukan enganalisis hubungan antara karakteristik penumpang dan status keselamatan penumpang.
2. Membangun dan mengevaluasi model Random Forest untuk memprediksi status keselamatan penumpang.
3. Menerapkan model yang telah dibangun untuk menghasilkan prediksi status keselamatan pada dataset lain.

2. METODELOGI PENELITIAN

Dataset

Dataset yang digunakan dalam penelitian ini adalah **dataset Titanic**, yang berisi data penumpang kapal RMS Titanic yang tenggelam pada tahun 1912. Dataset diperoleh dari repositori yang telah disediakan dan digunakan sebagai studi kasus untuk permasalahan klasifikasi keselamatan penumpang.

Dalam penelitian ini, dataset terdiri dari dua data, yaitu:

- Data latih (*training data*)
  Data latih digunakan untuk membangun dan mengevaluasi model klasifikasi Random Forest. Dataset ini terdiri dari sebanyak 891 data penumpang, yang masing-masing memiliki variabel karakteristik penumpang (serta label target *Survived*.
- Data prediksi (*prediction data*)
  Data prediksi digunakan untuk menguji kemampuan model dalam melakukan prediksi terhadap data baru yang belum memiliki label keselamatan. Dataset ini terdiri dari sebanyak 418 data penumpang.

Variabel Penelitian

Variabel yang digunakan dalam penelitian ini terdiri dari satu variabel target dan beberapa variabel prediktor. Rincian variabel penelitian disajikan pada tabel berikut.

Tabel 1. Variabel Data Penelitian

No.	Variabel	Keterangan	Jenis Data
1.	*Survived*	Status keselamatan penumpang (1 = selamat, 0 = tidak selamat)	Kategorik (biner)
2.	*Pclass*	Kelas tiket penumpang (1 = kelas atas, 2 = kelas menengah, 3 = kelas bawah)	Kategorik (ordinal)
3.	*Sex*	Jenis kelamin penumpang	kategorik (nominal)

4.	*Age*	Usia penumpang	Numerik (rasio)
5.	*SibSP*	Jumlah saudara kandung dan/atau pasangan yang ikut bersama penumpang	Numerik (diskrit)
6.	*Parch*	Jumlah orang tua dan/atau anak yang ikut bersama penumpang	Numerik (diskrit)
7.	*Fare*	Harga tiket yang dibayarkan penumpang	Numerik (rasio)
8.	*Embarked*	Pelabuhan keberangkatan (C= Cherbourg, Q = Queenstown, S = Southampton)	kategorik (nominal)

Dalam pemodelan, variabel PassengerId, Name, Ticket, dan Cabin tidak digunakan karena tidak memberikan kontribusi langsung terhadap prediksi keselamatan penumpang. *PassengerId* hanya berfungsi sebagai identitas, *Name* dan *Ticket* bersifat deskriptif, sedangkan *Cabin* memiliki banyak nilai kosong. Oleh karena itu, variabel-variabel tersebut dihapus pada tahap *data preparation* untuk meningkatkan kualitas model.

Metode Penelitian

Metode yang digunakan dalam penelitian ini adalah *Random Forest Classifier*, yaitu algoritma *ensemble learning* yang bekerja dengan membangun banyak pohon keputusan (*decision tree*) dan menggabungkan hasil prediksinya untuk menentukan keputusan akhir. Seluruh proses analisis, pemodelan, dan evaluasi dilakukan menggunakan bahasa pemrograman Python pada lingkungan Google Colab.

Random Forest dipilih karena mampu menangani data numerik dan kategorikal dengan baik, tidak sensitif terhadap perbedaan skala data sehingga tidak memerlukan normalisasi, serta memiliki kemampuan yang lebih baik dalam mengurangi *overfitting* dibandingkan satu pohon keputusan. Metode ini sesuai untuk permasalahan klasifikasi biner, seperti prediksi keselamatan penumpang Titanic.

Secara umum, *Random Forest* bekerja dengan mengambil sampel acak dari data latih (*bootstrap sampling*), membangun sejumlah pohon keputusan berdasarkan subset fitur acak, kemudian menggabungkan hasil prediksi seluruh pohon menggunakan mekanisme *majority voting*.

Langkah-Langkah Penelitian

Exploratory Data Analysis

EDA dilakukan untuk memperoleh wawasan awal mengenai karakteristik data. Tahap ini dibagi menjadi dua jenis analisis:

1. Non-graphical yaitu yaitu pemeriksaan tipe data, deskripsi statistik, identifikasi nilai yang hilang, dan pemeriksaan data duplikat.
2. Graphical yaitu meliputi analisis univariate dan multivariate:
   - Univariate Analysis yaitu memvisualisasikan distribusi variabel numerik dan kategorikal, misalnya usia, tarif tiket, jenis kelamin, dan pelabuhan keberangkatan.
   - Univariate Analysis yaitu Memvisualisasikan distribusi variabel numerik dan kategorikal, misalnya usia, tarif tiket, jenis kelamin, dan pelabuhan keberangkatan.

Data Preparation

Tahap ini bertujuan menyiapkan data agar layak digunakan dalam pemodelan. Langkah-langkahnya meliputi:

1. Handling Missing Value
   Baris dengan nilai kosong pada variabel *Age* dan *Embarked* dihapus karena kedua variabel ini penting untuk prediksi keselamatan.

2. Menghapus Variabel Noise
   Kolom *PassengerId, Name, Ticket*, dan *Cabin* dihapus karena tidak memberikan kontribusi langsung terhadap prediksi.
3. Feature Encoding
   Variabel kategorikal *Sex* dan *Embarked* diubah menjadi format numerik menggunakan one-hot encoding, sehingga seluruh fitur dapat digunakan oleh algoritma Random Forest.

Penanganan Data Tidak Seimbang (Imbalanced Data)

Dataset Titanic asli memiliki jumlah sampel yang tidak seimbang antara penumpang selamat dan tidak selamat. Untuk mengatasi hal ini, digunakan *RandomOverSampler*, yang menambahkan sampel pada kelas minoritas hingga seimbang dengan kelas mayoritas. Hal ini bertujuan agar model tidak bias terhadap kelas mayoritas saat dilatih.

Split Data

Data yang sudah seimbang dibagi menjadi dua bagian, yaitu data latih dan data tes. Pembagian dilakukan secara acak dengan proporsi 90:10.

Random Forest

Metode klasifikasi *Random Forest* merupakan pengembangan dari metode CART (*Classification and Regression Tree*). Algoritma ini bekerja dengan membangun sejumlah pohon keputusan dari data latih, di mana setiap pohon memberikan prediksi kelas secara independen. Keputusan akhir ditentukan berdasarkan mayoritas suara (*majority vote*) dari seluruh pohon yang terbentuk.

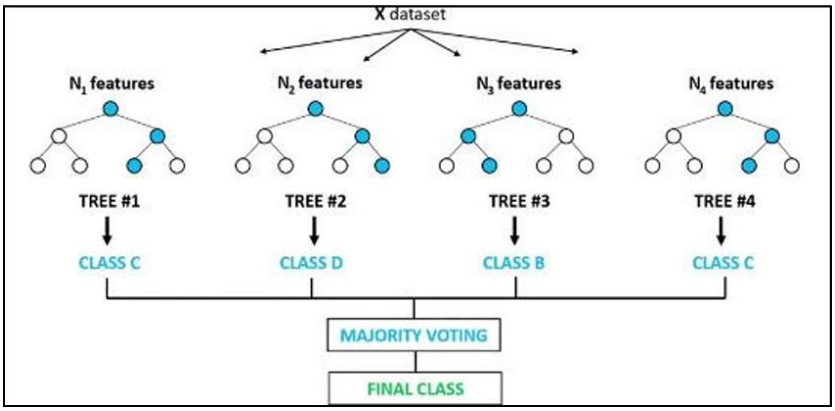

Gambar 1. Konsep Random Forest

Tiga prisip utama Random Forest adalah:
1. *Bootstrap sampling*: Mengambil sampel acak dari data latih untuk membangun setiap pohon.
2. Pemilihan fitur acak: Pada setiap node pohon, algoritma memilih subset fitur secara acak untuk menentukan pemisahan terbaik.
3. *Majority voting*: Menggabungkan prediksi dari seluruh pohon untuk menentukan kelas akhir.

Random Forest memiliki beberapa keunggulan diantaranya adalah akurasi tinggi karena menggabungkan banyak pohon, relatif tahan terhadap *outlier* dan *noise*, serta mudah diinterpretasikan. Dalam penelitian ini, *Random Forest* digunakan untuk memprediksi keselamatan penumpang Titanic karena mampu menangani variabel numerik dan kategorikal secara efektif, tidak sensitif terhadap skala data sehingga tidak memerlukan normalisasi, dan memiliki kemampuan yang lebih baik dalam mengurangi risiko *overfitting* dibandingkan penggunaan satu pohon keputusan (Wanda Dwi Febrianti).

Evaluasi Model

Evaluasi model dilakukan untuk menilai sejauh mana kinerja model Random Forest Classifier yang telah dilatih mampu memprediksi status keselamatan penumpang Titanic. Dalam penelitian ini, metrik evaluasi yang digunakan meliputi *accuracy, confusion matrix*, dan metrik turunan seperti *precision, recall*, dan *F1-score*.

1. *Confusion matrix*

   Confusion matrix memberikan gambaran distribusi hasil prediksi model terhadap data uji. Matriks ini menunjukkan jumlah prediksi yang benar dan salah, terbagi dalam empat kategori: True Positive (TP), True Negative (TN), False Positive (FP), dan False Negative (FN) (Kuncoro Singih Prasojo, 2025).

Tabel 2. *Confusion matrix*

Prediksi/Aktual	***Tidak Selamat***	**Selamat**
Prediksi False	*True Negative*	*False Negative*
Prediksi True	*False Positive*	*True Positive*

- *True Positive* (TP): jumlah penumpang yang selamat dan diprediksi selamat oleh model.
- *True Negative* (TN): jumlah penumpang yang tidak selamat dan diprediksi tidak selamat oleh model.
- *False Positive* (FP): jumlah penumpang yang sebenarnya tidak selamat, tetapi diprediksi selamat.
- *False Negative* (FN): jumlah penumpang yang sebenarnya selamat, tetapi diprediksi tidak selamat.

2. *Precision, Recall,* dan *F1-Score*

   Selain *accuracy*, performa model juga dievaluasi menggunakan metrik *precision, recall*, dan *F1-score. Precision* mengukur proporsi prediksi yang benar dari seluruh prediksi positif, sedangkan recall menunjukkan seberapa besar proporsi kasus positif yang berhasil diidentifikasi dengan benar oleh model. *F1-score* merupakan rata-rata harmonis antara *precision* dan *recall*, sehingga memberikan ukuran keseimbangan antara kemampuan model dalam melakukan prediksi yang tepat dan menangkap seluruh kasus positif (itbox.id, 2025).

Prediksi Data Baru

Setelah model Random Forest dilatih dan dievaluasi, model kemudian diterapkan ke seluruh data prediksi yang telah diproses. Data ini menghasilkan prediksi biner (1 = selamat, 0 = tidak selamat) untuk setiap penumpang, yang selanjutnya disimpan sebagai output akhir.

3. HASIL DAN PEMBAHASAN

Exploratory Data Analysis

Exploratory Data Analysis (EDA) dilakukan untuk memahami karakteristik dan distribusi data penumpang Titanic sebelum pemodelan.

	PassengerId	Survived	Pclass	Age	SibSp	Parch	Fare
count	891.000000	891.000000	891.000000	714.000000	891.000000	891.000000	891.000000
mean	446.000000	0.383838	2.308642	29.699118	0.523008	0.381594	32.204208
std	257.353842	0.486592	0.836071	14.526497	1.102743	0.806057	49.693429
min	1.000000	0.000000	1.000000	0.420000	0.000000	0.000000	0.000000
25%	223.500000	0.000000	2.000000	20.125000	0.000000	0.000000	7.910400
50%	446.000000	0.000000	3.000000	28.000000	0.000000	0.000000	14.454200
75%	668.500000	1.000000	3.000000	38.000000	1.000000	0.000000	31.000000
max	891.000000	1.000000	3.000000	80.000000	8.000000	6.000000	512.329200

Gambar 2. Statistik Desktiptif

Berdasarkan statistik deskriptif, rata-rata usia penumpang Titanic adalah 29,7 tahun (termuda 0,42 tahun, tertua 80 tahun), mayoritas berada di kelas tiket menengah dan bawah, dan sekitar 38% penumpang selamat. Sebagian besar penumpang bepergian sendiri atau dengan sedikit anggota keluarga (*SibSp* rata-rata 0,52, *Parch* 0,38). Tarif tiket bervariasi luas, dari 0 hingga 512,33, menunjukkan adanya *outlie*r. Data ini mencerminkan heterogenitas usia, kelas, dan biaya tiket yang perlu diperhatikan dalam pemodelan.

	0
PassengerId	0
Survived	0
Pclass	0
Name	0
Sex	0
Age	177
SibSp	0
Parch	0
Ticket	0
Fare	0
Cabin	687
Embarked	2

Gambar 3. Pengecekan *Missing Values*

Selain itu, pengecekan data menunjukkan tidak ada duplikasi pada dataset. Namun, terdapat nilai yang hilang pada beberapa variabel, yaitu *Age* (177 data), *Cabin* (687 data), dan *Embarked* (2 data), yang perlu ditangani pada tahap data preparation sebelum pemodelan. Variabel lainnya lengkap tanpa missing value.

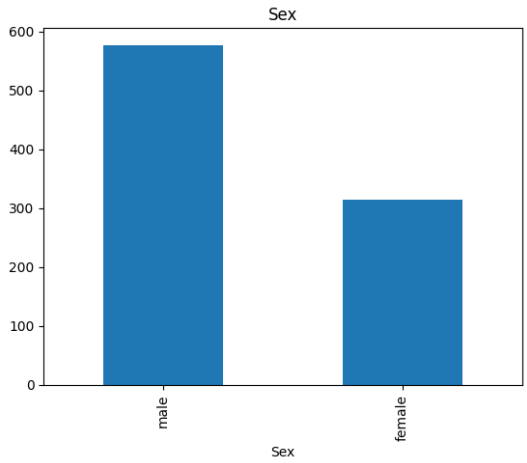

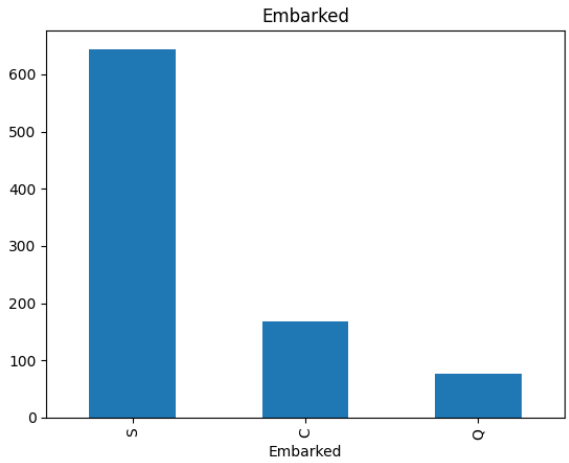

Gambar 4. Distribusi Jenis Kelamin
Gambar 5. Distribusi Pelabuhan Keberangkatan

Beralih ke graphical EDA, analisis dimulai dengan *Univariate Analysis* untuk melihat distribusi tiap variabel. Distribusi kategori Sex dan *Embarked* digabungkan untuk memudahkan perbandingan. Dari

visualisasi terlihat bahwa jumlah penumpang laki-laki lebih banyak dibandingkan perempuan dan sebagian besar penumpang berangkat dari pelabuhan Southampton, diikuti Cherbourg dan Queenstown.

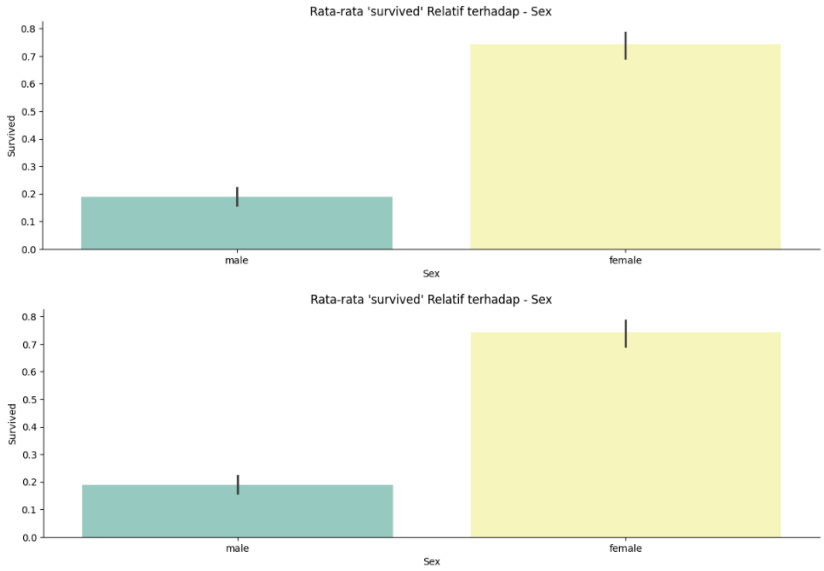

Gambar 6. Hubungan Fitur dengan Target (*Survived*)

Selanjutnya, *Multivariate Analysis* dilakukan untuk menilai hubungan variabel kategori dengan target Survived. Visualisasi hubungan *Embarked* dan *Survived* menunjukkan bahwa penumpang yang memiliki kemungkinan lebih besar untuk selamat adalah perempuan dan mereka yang berangkat dari pelabuhan *Cherbourg*.

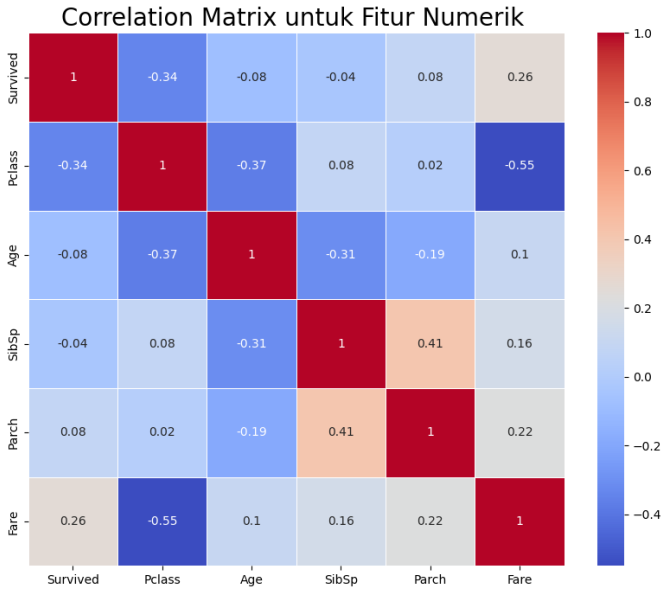

Gambar 7. Matriks Korelasi Untuk Fitur Numerik

Kemudian Pairplot antar fitur numerik (*Survived, Pclass, Age, SibSp, Parch, Fare*) menunjukkan bahwa korelasi antar variabel relatif rendah. Selanjutnya, matriks korelasi menegaskan bahwa hampir semua fitur memiliki korelasi rendah terhadap satu sama lain, dengan variabel *Fare* atau tarif tiket tampak memiliki pengaruh paling besar terhadap keselamatan penumpang dibandingkan variabel numerik lainnya.

Data Preparation

Tahap data preparation dilakukan untuk memastikan data yang digunakan dalam pemodelan berada dalam kondisi bersih, konsisten, dan siap diolah oleh algoritma machine learning. Proses ini meliputi:

1. *Handling Missing Value*
   Penanganan *missing value* dilakukan dengan menghapus data yang memiliki nilai kosong pada variabel *Age* dan *Embarked*.
2. Menghapus Variabel Noise
   variabel yang tidak berkontribusi langsung terhadap proses klasifikasi, yaitu *PassengerId, Name, Ticket,* dan *Cabin*, dihapus karena bersifat identitas atau memiliki tingkat kekosongan yang tinggi sehingga tidak relevan untuk meningkatkan performa model.
3. Feature Encoding
   Mengubah variabel kategorikal, yaitu *Sex* dan *Embarked*, ke dalam bentuk numerik menggunakan teknik *one-hot encoding*. Proses ini bertujuan agar data dapat diproses oleh algoritma Random Forest yang memerlukan input numerik. Setelah selesai, dataset menjadi terdiri dari 11 fitur numerik termasuk variabel *Survived.*

Tabel 3. Data Fitur Hasil Feature Encoding

No	Nama Fitur	Tipe data
1	*survived*	Integer
2	*Pclass*	Integer
3	*Age*	Float
4	*SibSp*	Integer
5	*Parch*	Integer
6	*Fare*	Float
7	*Sex_Female*	Integer
8	*Sex_Male*	Integer
9	*Embarked_C*	Integer
10	*Embarked_Q*	Integer
11	*Embarked_S*	Integer

4. Handling Imbalanced Data
   Setelah proses *feature encoding*, dilakukan penanganan ketidakseimbangan kelas (*imbalanced data*) pada variabel target *Survived*. Penanganan dilakukan menggunakan metode *Random Over Sampling*, yang bertujuan untuk menyeimbangkan jumlah data pada masing-masing kelas dengan cara menambah sampel pada kelas minoritas. Tahap ini dilakukan agar model tidak bias terhadap kelas mayoritas.
   Setelah proses *oversampling* dilakukan, jumlah data meningkat dari 712 data menjadi 848 data, dengan distribusi kelas yang seimbang. Dataset hasil *oversampling* ini kemudian digunakan pada tahap pembagian data menjadi data latih dan data uji.

Split Data

Tahap selanjutnya adalah pembagian data menjadi data latih (*training data*) dan data uji (*testing data*). Data dibagi dengan rasio 90% data latih dan 10% data uji. Dari hasil pembagian tersebut, diperoleh :

Tabel 4. Hasil Split Data Dengan Perbandingan 90:10

Data latih	763 data
Data uji	85 data

Data latih digunakan untuk membangun model, sedangkan data uji digunakan untuk mengevaluasi kinerja model.

Modelling dan Evaluasi Model

Pada tahap ini dilakukan pemodelan menggunakan algoritma *Random Forest Classifier* untuk memprediksi keselamatan penumpang Titanic. Model dilatih menggunakan data latih dan kemudian diuji menggunakan data uji untuk mengukur kemampuan generalisasi model terhadap data yang belum pernah dilihat sebelumnya.

Evaluasi model dilakukan untuk menilai kinerja algoritma *Random Forest Classifier* dalam mengklasifikasikan penumpang yang selamat dan tidak selamat. Metode evaluasi yang digunakan meliputi *confusion matrix* serta evaluasi kinerja model, yaitu *precision, recall, dan F1-score*, yang memberikan gambaran lebih rinci mengenai ketepatan dan keseimbangan prediksi model.

Tabel 5. Confusion Matrix

Prediksi/Aktual	***Tidak Selamat***	**Selamat**
Prediksi False	*38*	*7*
Prediksi True	*1*	*39*

Tabel 6. Hasil Evaluasi Kinerja Model Klasifikasi

Metrik	**Nilai**
Precision (tidak selamat)	0.97
Precision (selamat)	0.85
Recall (tidak selamat)	0.84
Recall (selamat)	0.97
F1-score (tidak selamat)	0.90
F1-score (selamat)	0.91

Berdasarkan confusion matrix tersebut, model mampu mengklasifikasikan sebagian besar data dengan benar. Sebanyak 38 penumpang yang tidak selamat dan 39 penumpang yang selamat berhasil diprediksi dengan tepat. Kesalahan prediksi relatif kecil, yaitu 7 data *false negative* dan 1 data *false positive*, yang menunjukkan bahwa model memiliki kemampuan klasifikasi yang baik dan seimbang pada kedua kelas.

Kemudian model memiliki accuracy sebesar 0,91, yang menandakan performa klasifikasi yang baik. Kelas tidak selamat (0) memiliki precision tinggi (0,97) namun recall lebih rendah (0,84), sedangkan kelas selamat (1) memiliki recall sangat tinggi (0,97) dengan precision 0,85. Secara keseluruhan, model sangat baik dalam mengidentifikasi penumpang yang selamat dan mampu membedakan kedua kelas secara seimbang.

Penerapan Model Pada Data Prediksi

Sebelum dilakukan prediksi, data prediksi terlebih dahulu melalui tahap data preparation agar memiliki struktur dan format yang sama dengan data latih. Tahapan ini meliputi penghapusan variabel yang tidak relevan, penanganan missing value, pengkodean variabel kategorikal, serta penyesuaian kolom agar sesuai dengan model yang telah dilatih.

Pada tahap *data preparation, variabel PassengerId, Name, Ticket*, dan *Cabin* dihapus karena tidak berkontribusi langsung terhadap proses klasifikasi. Penanganan missing value pada data prediksi yaitu:

- Variabel *Age* diisi dengan median dari data prediksi
- Variabel *Embarked* diisi dengan modus dari data prediksi

Berbeda dengan data latih, di mana baris yang memiliki *missing value* pada variabel Age dan Embarked dihapus untuk memastikan kualitas data model training.

Selanjutnya, variabel kategorikal *Sex* dan *Embarked* diubah menjadi numerik menggunakan *one-hot encoding*, menghasilkan kolom dengan nilai *True/False* untuk setiap kategori. Setelah itu, struktur kolom data prediksi disesuaikan dengan data latih menggunakan proses *reindexing*, sehingga semua fitur yang dibutuhkan oleh model tersedia dan kolom yang tidak ada diisi dengan nilai 0.

Setelah data siap, model *Random Forest* yang telah dilatih digunakan untuk memprediksi keselamatan penumpang pada data prediksi. Hasil prediksi disimpan dalam kolom prediction, yang berisi *True* untuk penumpang diprediksi selamat dan False untuk penumpang diprediksi tidak selamat, kemudian diekspor ke file hasil_Data_prediksi.xlsx.

Tabel 7. Distribusi Hasil Prediksi Pada Data Prediksi

Kelas Prediksi	Jumlah Data	Persentase (%)
Tidak Selamat (0)	241	57,66
Selamat (1)	177	42,34

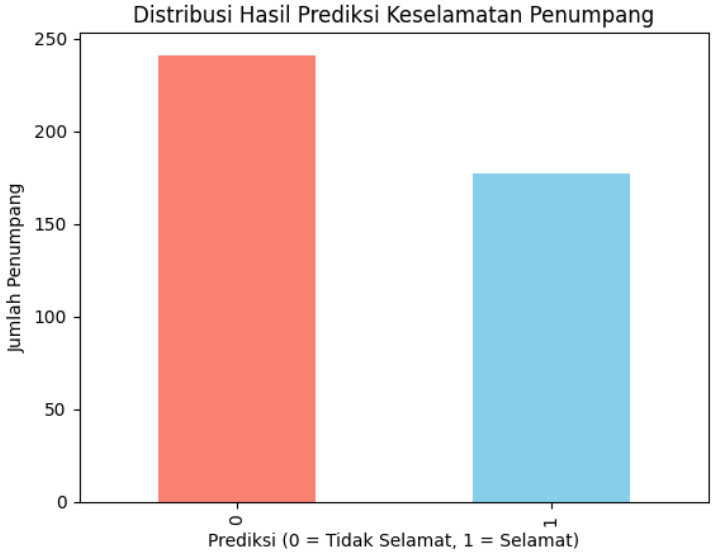

Gambar 8. Distribusi Hasil Prediksi

Berdasarkan hasil prediksi, mayoritas penumpang pada data prediksi diperkirakan tidak selamat, yaitu sebesar 57,66%, sedangkan 42,34% penumpang diprediksi selamat. Distribusi ini menunjukkan bahwa model cenderung memprediksi lebih banyak penumpang tidak selamat, yang sejalan dengan pola data latih Titanic di mana jumlah korban tidak selamat lebih dominan dibandingkan penumpang yang selamat.

5. KESIMPULAN DAN SARAN

Berdasarkan hasil analisis dan pemodelan yang telah dilakukan, dapat disimpulkan bahwa algoritma *Random Forest* mampu memprediksi keselamatan penumpang Titanic dengan performa yang baik. Hasil *Exploratory Data Analysis* (EDA) menunjukkan bahwa faktor jenis kelamin, pelabuhan keberangkatan, serta tarif penumpang memiliki keterkaitan dengan tingkat keselamatan penumpang. Penumpang perempuan dan penumpang dengan tarif perjalanan yang lebih tinggi cenderung memiliki peluang selamat yang lebih besar.

Tahap data preparation yang meliputi penanganan *missing value*, penghapusan variabel noise, *feature encoding*, serta penanganan ketidakseimbangan kelas berhasil meningkatkan kualitas data sehingga

model dapat dilatih secara optimal. Model *Random Forest* yang dibangun menghasilkan akurasi sebesar 91% pada data uji, dengan nilai precision, recall, dan F1-score yang seimbang pada kedua kelas. Hal ini menunjukkan bahwa model mampu mengklasifikasikan penumpang yang selamat dan tidak selamat secara efektif.

Pada tahap prediksi data baru, hasil distribusi prediksi menunjukkan bahwa mayoritas penumpang diprediksi tidak selamat, sesuai dengan kondisi historis kejadian tenggelamnya kapal Titanic. Dengan demikian, model yang dibangun tidak hanya memiliki performa yang baik secara statistik, tetapi juga mampu merepresentasikan pola kejadian secara logis.

Untuk penelitian selanjutnya, disarankan agar dilakukan eksplorasi fitur tambahan, seperti pengelompokan usia atau pembuatan fitur baru (*feature engineering*), guna meningkatkan performa model. Selain itu, metode penanganan *missing value* dapat dikembangkan menggunakan teknik imputasi daripada penghapusan data agar informasi yang tersedia tidak banyak berkurang.

Penelitian selanjutnya juga dapat membandingkan performa *Random Forest* dengan algoritma klasifikasi lain, seperti *Logistic Regression*, *Support Vector Machine*, atau *Gradient Boosting*, sehingga dapat diketahui metode yang paling optimal. Terakhir, penggunaan teknik validasi silang (*cross-validation*) disarankan untuk memperoleh evaluasi model yang lebih stabil dan menyeluruh.

DAFTAR PUSTAKA

Kuncoro Singih Prasojo, H. F. (2025). Analisis Kinerja Algoritma C4.5 pada Dataset Titanic yang Tidak Seimbang . *Jurnal Pengabdian Masyarakat dan Riset Pendidikan*.

Pratama, A., Nurcahyo, A. C., & Firgia, L. (2023, August 7). Penerapan Machine Learning dengan Algoritma Logistik Regresi Untuk Memprediksi Diabetes. *SEMINAR NASIONAL CORISINDO*, 116-121.Putri, S. U., Irawan, E., & Rizky, F. (2021, January). Implementasi Data Mining Untuk Prediksi Penyakit Diabetes Dengan Algoritma C4.5. *KESATRIA: Jurnal Penerapan Sistem Informasi (Komputer & Manajemen), II*(1),

Wanda Dwi Febrianti, N. K. (n.d.). Analisis Klasifikasi Kepuasan Penumpang Maskapai Penerbangan Menggunakan Metode Support Vector Machine, Decision Tree, Dan Random Forest. *Department of Statistics, Institut Teknologi Sepuluh Nopember Surabaya, Indonesia* .